16장 이미지 인식의 꽃, CNN 익히기

목 차

이미지 인식의 꽃, CNN 익히기

- **실습과제** MNIST 손글씨 인식

- 컴퓨터에게 이 글씨를 읽게 하고 이 글씨가 어떤 의미인지를 알게 하는 과정은 쉽지 않음

이미지 인식의 꽃, CNN 익히기

- MNIST 데이터셋은 미국 국립표준기술원(NIST)이 고등학생과 인구조사국 직원등이 쓴 손글씨를 이용해 만든 데이터로 구성되어 있음
  - → 70,000개의 글자 이미지에 각각 0부터 9까지 이름표를 붙인 데이터셋
  - → 머신러닝을 배우는 사람이라면 자신의 알고리즘과 다른 알고리즘의 성과를 비교해 보고자 한 번씩 도전해 보는 가장 유명한 데이터 중 하나임

이미지 인식의 꽃, CNN 익히기

그림 16-1 MNIST 손글씨 데이터 이미지

1 데이터 전처리

- MNIST 데이터는 케라스를 이용해 간단히 불러올 수 있음
- mnist.load_data( ) 함수로 사용할 데이터를 불러옴

```
from keras.datasets import mnist
```

1 데이터 전처리

- 학습에 사용될 부분: X_train, Y_class_train
- 테스트에 사용될 부분: X_test, Y_class_test

```
(X_train, Y_class_train), (X_test, Y_class_test) = mnist.load_data( )
```

1 데이터 전처리

- 케라스의 MNIST 데이터는 총 70,000개의 이미지 중 60,000개를 학습용으로, 10,000개를 테스트용으로 미리 구분해 놓고 있음

```
print("학습셋 이미지 수: %d 개" % (X_train.shape[0]))
print("테스트셋 이미지 수: %d 개" % (X_test.shape[0]))
```

```
학습셋 이미지 수: 60000 개
테스트셋 이미지 수: 10000 개
```

1 데이터 전처리

- 불러온 이미지 중 한 개만 다시 불러와 보겠음

```
import matplotlib.pyplot as plt
plt.imshow(X_train[0], cmap='Greys')
plt.show( )
```

1 데이터 전처리

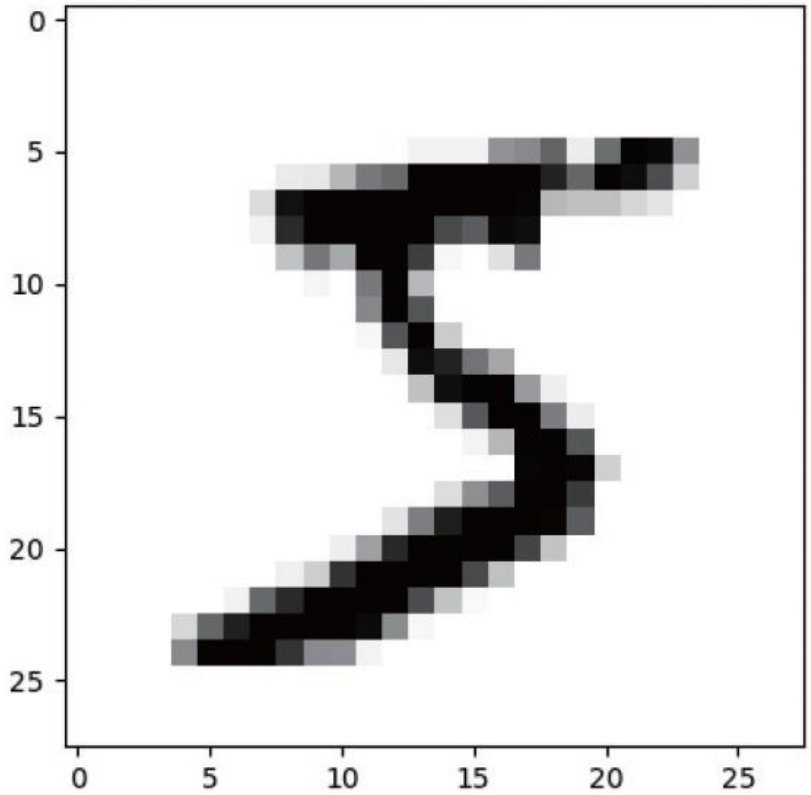

그림 16-2 MNIST 손글씨 데이터의 첫 번째 이미지

1 데이터 전처리

- 이 이미지는 가로 28 × 세로 28 = 총 784개의 픽셀로 이루어져 있음
- 각 픽셀은 밝기 정도에 따라 0부터 255까지의 등급을 매김
- 흰색 배경이 0이라면 글씨가 들어간 곳은 1~255까지 숫자 중 하나로 채워져 긴 행렬로 이루어진 하나의 집합으로 변환됨

```
for x in X_train[0]:
    for i in x:
        sys.stdout.write('%d\t' % i)
    sys.stdout.write('\n')
```

1 데이터 전처리

0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	3	18	18	18	126	136	175	26	166	255	247	127	0	0	0	0
0	0	0	0	0	0	0	0	30	36	94	154	170	253	253	253	253	253	225	172	253	242	195	64	0	0	0	0
0	0	0	0	0	0	0	49	238	253	253	253	253	253	253	253	253	251	93	82	82	56	39	0	0	0	0	0
0	0	0	0	0	0	0	18	219	253	253	253	253	253	198	182	247	241	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	80	156	107	253	253	205	11	0	43	154	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	14	1	154	253	90	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	139	253	190	2	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	11	190	253	70	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	35	241	225	160	108	1	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	81	240	253	253	119	25	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	45	186	253	253	150	27	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	16	93	252	253	187	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	249	253	249	64	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	46	130	183	253	253	207	2	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	39	148	229	253	253	253	250	182	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	24	114	221	253	253	253	253	201	78	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	23	66	213	253	253	253	253	198	81	2	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	18	171	219	253	253	253	253	195	80	9	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	55	172	226	253	253	253	253	244	133	11	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	136	253	253	253	212	135	132	16	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0

그림 16-3 그림의 각 좌표를 숫자로 표현해보기

1 데이터 전처리

- 바로 이렇게 이미지는 다시 숫자의 집합으로 바뀌어 학습셋으로 사용됨
- 이제 주어진 가로 28, 세로 28의 2차원 배열을 784개의 1차원 배열로 바꿔 주어야 하는데 이를 위해 reshape( ) 함수를 사용함
- reshape(총 샘플 수, 1차원 속성의 수) 형식으로 지정함

```
X_train = X_train.reshape(X_train.shape[0], 784)
```

1 데이터 전처리

- 정규화(normalization) :

  데이터의 폭이 클 때 적절한 값으로 분산의 정도를 바꾸는 과정

- 현재 주어진 데이터의 값은 0부터 255까지의 정수로, 정규화를 위해 255로 나누어 주려면 먼저 이 값을 실수형으로 바꿔야 함

```
X_train = X_train.astype('float64')
X_train = X_train / 255
```

1 데이터 전처리

- X_test에도 마찬가지로 이 작업을 적용함

```
X_test = X_test.reshape(X_test.shape[0], 784).astype('float64') / 255
```

- 실제로 이 숫자의 레이블이 어떤지를 불러오고자 Y_class_train[0]을 다음과 같이 출력해보자

```
print("class : %d " % (Y_class_train[0]))
```

1 데이터 전처리

- 이 숫자의 레이블 값인 5가 출력되는 것을 볼 수 있음

```
class : 5
```

- 아이리스 품종을 예측할 때 딥러닝의 분류 문제를 해결하려면 원-핫 인코딩 방식을 적용해야 함
- 즉, 0~9까지의 정수형 값을 갖는 현재 형태에서 0 또는 1로만 이루어진 벡터로 값을 수정해야 함

1 데이터 전처리

- 지금 우리가 열어본 이미지의 class는 [5]였음
- 이를 [0,0,0,0,0,1,0,0,0,0]로 바꿔야 함
- 이를 가능하게 해 주는 함수가 바로 np_utils.to_categorical( ) 함수임

```
Y_train = np_utils.to_categorical(Y_class_train,10)
Y_test = np_utils.to_categorical(Y_class_test,10)
```

1 데이터 전처리

- 이제 변환된 값을 출력해보자

```
print(Y_train[0])
```

- 아래와 같이 원-핫 인코딩이 적용된 것을 확인할 수 있음

```
[0. 0. 0. 0. 0. 1. 0. 0. 0. 0. 0.]
```

1 데이터 전처리

코드 16-1 MNIST 손글씨 인식하기: 데이터 전처리

- 예제 소스: run_project/14_MNIST_Data.ipynb

```
from keras.datasets import mnist
from keras.utils import np_utils

import numpy
import sys
import tensorflow as tf

# seed 값 설정
seed = 0
numpy.random.seed(seed)
tf.random.set_seed(3)
```

1 데이터 전처리

```
# MNIST 데이터셋 불러오기
(X_train, Y_class_train), (X_test, Y_class_test) = mnist.load_
data()

print("학습셋 이미지 수 : %d 개" % (X_train.shape[0]))
print("테스트셋 이미지 수 : %d 개" % (X_test.shape[0]))

# 그래프로 확인
import matplotlib.pyplot as plt
plt.imshow(X_train[0], cmap='Greys')
plt.show()

# 코드로 확인
for x in X_train[0]:
```

1 데이터 전처리

```
    for i in x:
        sys.stdout.write('%d\t' % i)
    sys.stdout.write('\n')

# 차원 변환 과정
X_train = X_train.reshape(X_train.shape[0], 784)
X_train = X_train.astype('float64')
X_train = X_train / 255

X_test = X_test.reshape(X_test.shape[0], 784).astype('float64') /
255

# 클래스 값 확인
print("class : %d " % (Y_class_train[0]))
```

1 데이터 전처리

```
# 바이너리화 과정
Y_train = np_utils.to_categorical(Y_class_train, 10)
Y_test = np_utils.to_categorical(Y_class_test, 10)

print(Y_train[0])
```

2 딥러닝 기본 프레임 만들기

- 총 60,000개의 학습셋과 10,000개의 테스트셋을 불러와 속성 값을 지닌 X, 클래스 값을 지닌 Y로 구분하는 작업

```
from keras.datasets import mnist

(X_train, Y_train), (X_test, Y_test) = mnist.load_data( )

X_train = X_train.reshape(X_train.shape[0], 784).
astype('float32') / 255
X_test = X_test.reshape(X_test.shape[0], 784).astype('float32') /
255

Y_train = np_utils.to_categorical(Y_train, 10)
Y_test = np_utils.to_categorical(Y_test, 10)
```

2 딥러닝 기본 프레임 만들기

- 이제 딥러닝을 실행하고자 프레임을 설정함

```
model = Sequential( )
model.add(Dense(512, input_dim=784, activation='relu'))
model.add(Dense(10, activation='softmax'))
```

- 활성화 함수로 은닉층에서는 relu를, 출력층에서는 softmax를 사용함

2 딥러닝 기본 프레임 만들기

- 딥러닝 실행 환경을 위해 오차 함수로 categorical_crossentropy, 최적화 함수로 adam을 사용함

```
model.compile(loss='categorical_crossentropy',
              optimizer='adam',
              metrics=['accuracy'])
```

2 딥러닝 기본 프레임 만들기

- 모델의 실행에 앞서 모델의 성과를 저장하고 모델의 최적화 단계에서 학습을 자동 중단하게끔 설정함
- 10회 이상 모델의 성과 향상이 없으면 자동으로 학습을 중단함

2 딥러닝 기본 프레임 만들기

```
import os
from keras.callbacks import ModelCheckpoint,EarlyStopping

MODEL_DIR = './model/'
if not os.path.exists(MODEL_DIR):
    os.mkdir(MODEL_DIR)

modelpath="./model/{epoch:02d}-{val_loss:.4f}.hdf5"
checkpointer = ModelCheckpoint(filepath=modelpath, monitor='val_
loss', verbose=1, save_best_only=True)
early_stopping_callback = EarlyStopping(monitor='val_loss',
patience=10)
```

2 딥러닝 기본 프레임 만들기

- 샘플 200개를 모두 30번 실행하게끔 설정함
- 테스트셋으로 최종 모델의 성과를 측정하여 그 값을 출력함

```
history = model.fit(X_train, Y_train, validation_data=(X_test, Y_
test), epochs=30, batch_size=200, verbose=0, callbacks=[early_
stopping_callback,checkpointer])

print("\n Test Accuracy: %.4f" % (model.evaluate(X_test, Y_test)[1]))
```

2 딥러닝 기본 프레임 만들기

- 학습셋의 오차는 1에서 학습셋의 정확도를 뺀 값임
- 좀 더 세밀한 변화를 볼 수 있게 학습셋의 오차와 테스트셋의 오차를 그래프 하나로 나타냄

```
import matplotlib.pyplot as plt

y_vloss = history.history['val_loss']

# 학습셋의 오차
y_loss = history.history['loss']
```

2 딥러닝 기본 프레임 만들기

```
# 그래프로 표현
x_len = numpy.arange(len(y_loss))
plt.plot(x_len, y_vloss, marker='.', c="red", label='Testset_
loss')
plt.plot(x_len, y_loss, marker='.', c="blue", label='Trainset_
loss')

# 그래프에 그리드를 주고 레이블을 표시
plt.legend(loc='upper right')
plt.grid()
plt.xlabel('epoch')
plt.ylabel('loss')
plt.show()
```

2 딥러닝 기본 프레임 만들기

코드 16-2 MNIST 손글씨 인식하기: 기본 프레임

- 예제 소스: run_project/15_MNIST_Simple.ipynb

```
from keras.datasets import mnist
from keras.utils import np_utils
from keras.models import Sequential
from keras.layers import Dense
from keras.callbacks import ModelCheckpoint,EarlyStopping

import matplotlib.pyplot as plt
import numpy
import os
import tensorflow as tf
```

2 딥러닝 기본 프레임 만들기

```
# seed 값 설정
seed = 0
numpy.random.seed(seed)
tf.set_random_seed(3)

# MNIST 데이터 불러오기
(X_train, Y_train), (X_test, Y_test) = mnist.load_data( )

X_train = X_train.reshape(X_train.shape[0], 784).
astype('float32') / 255
X_test = X_test.reshape(X_test.shape[0], 784).astype('float32') /
255
```

2 딥러닝 기본 프레임 만들기

```
Y_train = np_utils.to_categorical(Y_train, 10)
Y_test = np_utils.to_categorical(Y_test, 10)
# 모델 프레임 설정
model = Sequential()
model.add(Dense(512, input_dim=784, activation='relu'))
model.add(Dense(10, activation='softmax'))

# 모델 실행 환경 설정
model.compile(loss='categorical_crossentropy',
              optimizer='adam',
              metrics=['accuracy'])
```

2 딥러닝 기본 프레임 만들기

```
# 모델 최적화 설정
MODEL_DIR = './model/'
if not os.path.exists(MODEL_DIR):
    os.mkdir(MODEL_DIR)

modelpath="./model/{epoch:02d}-{val_loss:.4f}.hdf5"
checkpointer = ModelCheckpoint(filepath=modelpath, monitor='val_
loss', verbose=1, save_best_only=True)
early_stopping_callback = EarlyStopping(monitor='val_loss',
patience=10)
```

2 딥러닝 기본 프레임 만들기

```
# 모델의 실행
history = model.fit(X_train, Y_train, validation_data=(X_test, Y_
test), epochs=30, batch_size=200, verbose=0, callbacks=[early_
stopping_callback,checkpointer])

# 테스트 정확도 출력
print("\n Test Accuracy: %.4f" % (model.evaluate(X_test, Y_test)
[1]))

# 테스트셋의 오차
y_vloss = history.history['val_loss']
```

2 딥러닝 기본 프레임 만들기

```
# 학습셋의 오차
y_loss = history.history['loss']

# 그래프로 표현
x_len = numpy.arange(len(y_loss))
plt.plot(x_len, y_vloss, marker='.', c="red", label='Testset_
loss')
plt.plot(x_len, y_loss, marker='.', c="blue", label='Trainset_
loss')
```

2 딥러닝 기본 프레임 만들기

```
# 그래프에 그리드를 주고 레이블을 표시
plt.legend(loc='upper right')
# plt.axis([0, 20, 0, 0.35])
plt.grid()
plt.xlabel('epoch')
plt.ylabel('loss')
plt.show()
```

2 딥러닝 기본 프레임 만들기

실행 결과

```
Epoch 00000: val_loss improved from inf to 0.15460, saving model to ./
model/00-0.1546.hdf5
Epoch 00001: val_loss improved from 0.15460 to 0.10492, saving model to ./
model/01-0.1049.hdf5
Epoch 00002: val_loss improved from 0.10492 to 0.08447, saving model to ./
model/02-0.0845.hdf5
Epoch 00003: val_loss improved from 0.08447 to 0.07896, saving model to ./
model/03-0.0790.hdf5
Epoch 00004: val_loss improved from 0.07896 to 0.06699, saving model to ./
model/04-0.0670.hdf5
Epoch 00005: val_loss improved from 0.06699 to 0.06388, saving model to ./
model/05-0.0639.hdf5
```

```
Epoch 00006: val_loss did not improve
Epoch 00007: val_loss improved from 0.06388 to 0.06291, saving model to ./model/07-0.0629.hdf5
Epoch 00008: val_loss improved from 0.06291 to 0.05828, saving model to ./model/08-0.0583.hdf5
Epoch 00009: val_loss did not improve
Epoch 00010: val_loss did not improve
Epoch 00011: val_loss did not improve
Epoch 00012: val_loss did not improve
Epoch 00013: val_loss did not improve
Epoch 00014: val_loss did not improve
```

2 딥러닝 기본 프레임 만들기

```
Epoch 00015: val_loss did not improve
Epoch 00016: val_loss did not improve
Epoch 00017: val_loss did not improve
Epoch 00018: val_loss did not improve
Epoch 00019: val_loss did not improve
 9920/10000 [==============================>.] - ETA: 0s
 Test Accuracy: 0.9821
```

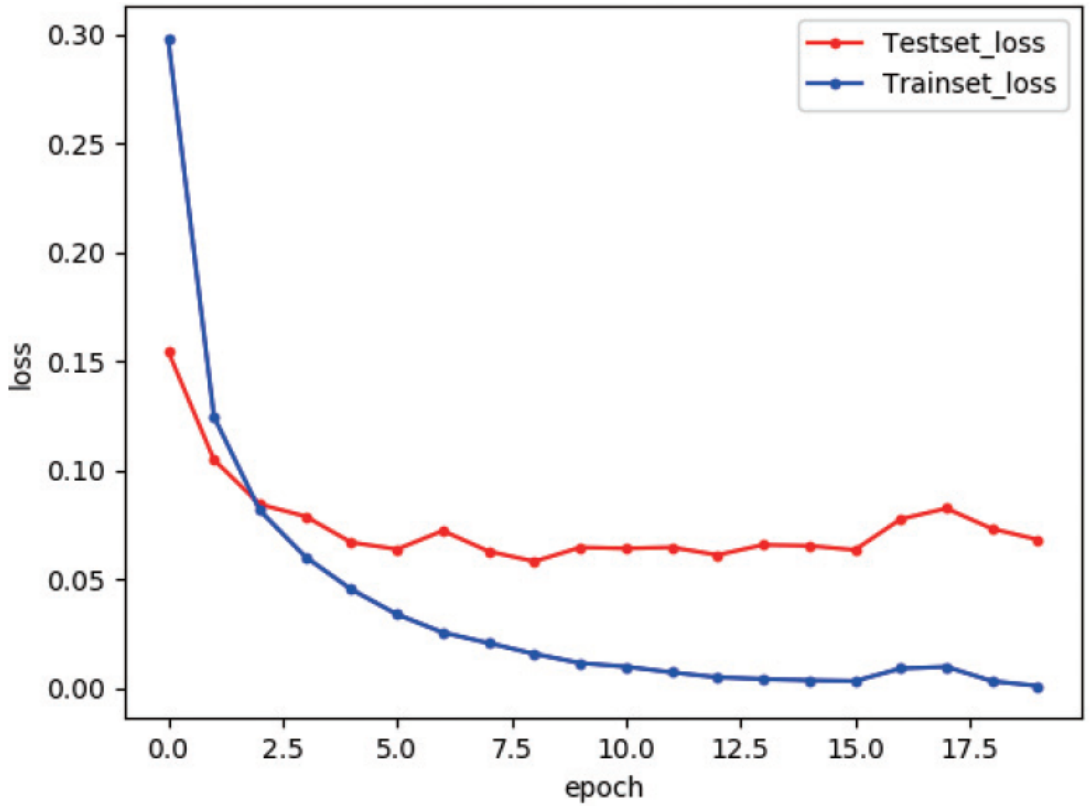

그림 16-4 학습이 진행될 때 학습셋과 테스트셋의 오차 변화

2 딥러닝 기본 프레임 만들기

- 학습셋에 대한 오차는 계속해서 줄어듦
- 테스트셋의 과적합이 일어나기 전 학습을 끝낸 모습임

TIP

그림 16-4는 학습셋의 오차(Trainset_loss)와 테스트셋의 오차(Testset_loss)를 그래프로 표현한 것입니다. 앞서 학습셋과 테스트셋을 배울 때는 학습셋의 정확도(Trainset_acc)를 이용했습니다(그림 14-1). 하지만 학습셋의 정확도는 1.00에 가깝고 테스트셋의 오차는 0.00에 가까우므로 두 개를 함께 비교하기가 어렵습니다. 따라서 1에서 학습셋의 정확도를 뺀 값, 즉 학습셋의 오차를 주로 그래프에 적용하여 이와 같이 표현합니다.

3 더 깊은 딥러닝

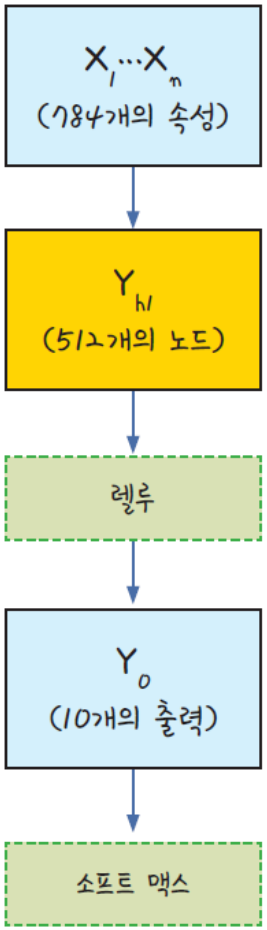

- 앞서 98.21%의 정확도를 보인 딥러닝 프레임은 하나의 은닉층을 둔 아주 단순한 모델
- 딥러닝은 이러한 기본 모델을 바탕으로,
  → 프로젝트에 맞춰서 어떤 옵션을 더하고 어떤 층을 추가하느냐에 따라 성능이 좋아질 수 있음

그림 16-5 은닉층이 하나인 딥러닝 모델의 도식

4 컨볼루션 신경망(CNN)

- 컨볼루션 신경망 :

  입력된 이미지에서 다시 한번 특징을 추출하기 위해 마스크(필터, 윈도 또는 커널이라고도 함)를 도입하는 기법

1	0	1	0
0	1	1	0
0	0	1	1
0	0	1	0

4 컨볼루션 신경망(CNN)

- 여기에 2×2 마스크를 준비함
- 각 칸에는 가중치가 들어있음
- 샘플 가중치를 다음과 같이 ×1, ×0라고 함

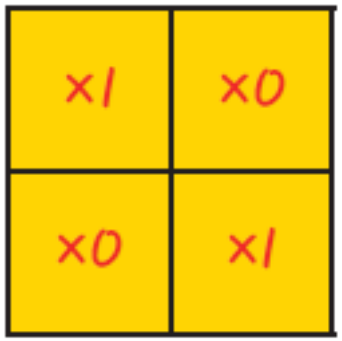

4 컨볼루션 신경망(CNN)

- 이제 마스크를 맨 왼쪽 위칸에 적용시켜 보자

1×1	0×0	1	0
0×0	1×1	1	0
0	0	1	1
0	0	1	0

4 컨볼루션 신경망(CNN)

- 적용된 부분은 원래 있던 값에 가중치의 값을 곱해 줌
- 그 결과를 합하면 새로 추출된 값은 2가 됨

$$(1\times 1)+(0\times 0)+(0\times 0)+(1\times 1)=2$$

- 이 마스크를 한 칸씩 옮겨 모두 적용해 보자

4 컨볼루션 신경망(CNN)

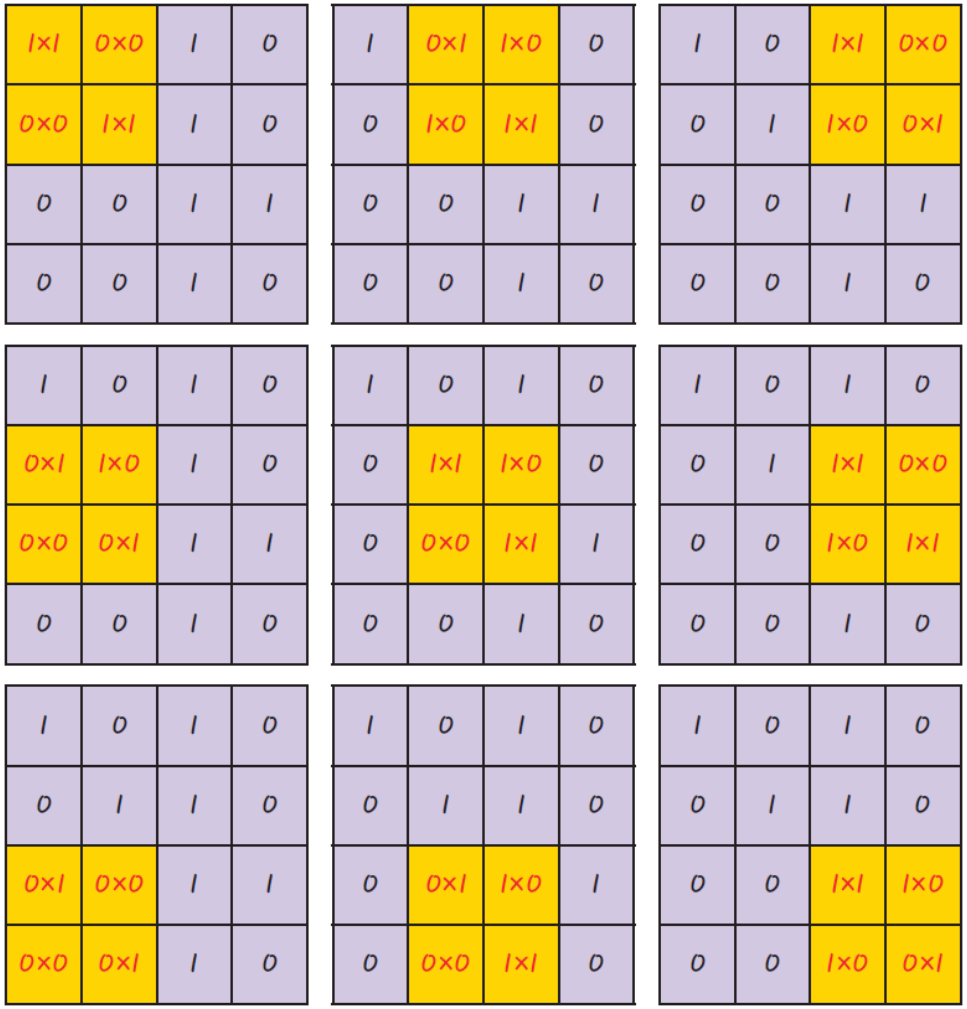

4 컨볼루션 신경망(CNN)

- 그 결과를 정리하면 다음과 같음

2	1	1
0	2	2
0	1	1

4 컨볼루션 신경망(CNN)

- 새롭게 만들어진 층을 컨볼루션(합성곱)이라고 부름
- 컨볼루션을 만들면 입력 데이터로부터 더욱 정교한 특징을 추출할 수 있음

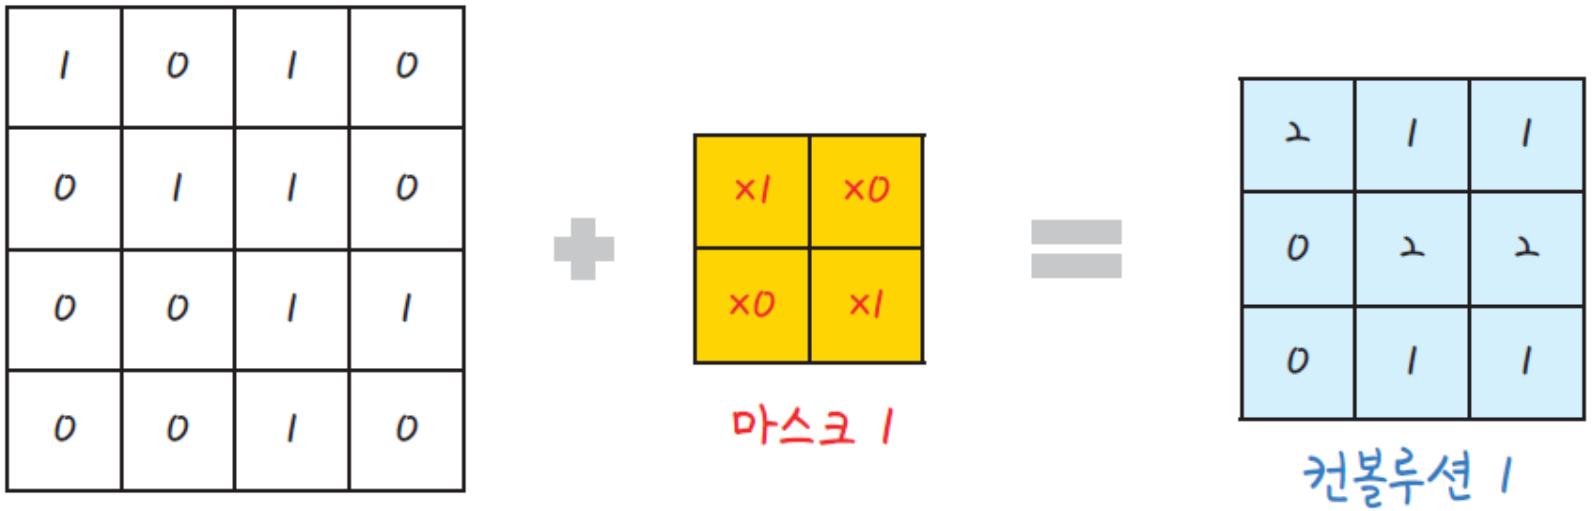

4 컨볼루션 신경망(CNN)

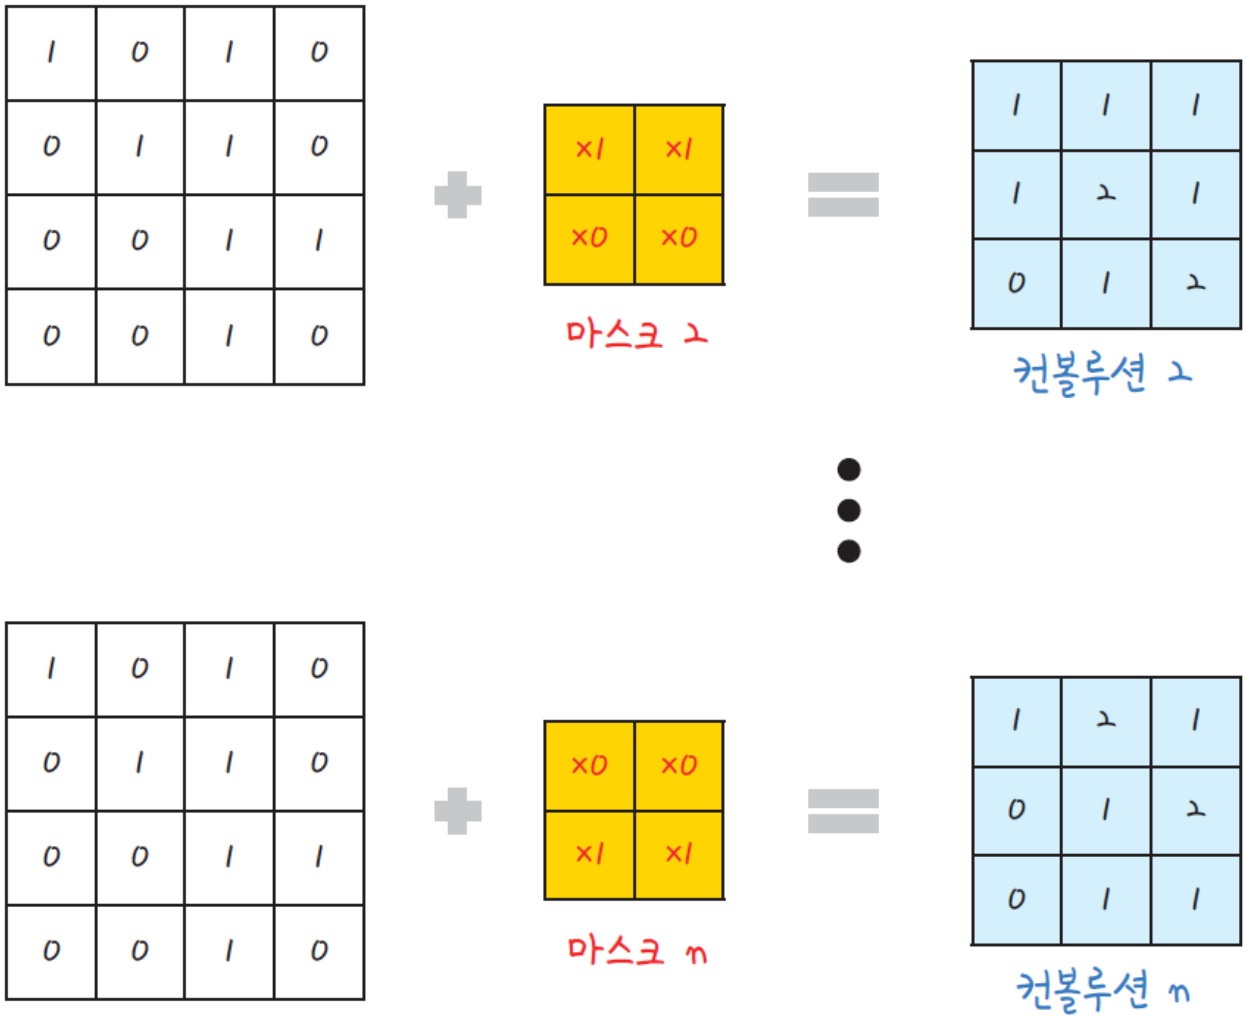

4 컨볼루션 신경망(CNN)

- 케라스에서 컨볼루션 층을 추가하는 함수는 Conv2D( )임
- 다음과 같이 컨볼루션 층을 적용하여 MNIST 손글씨 인식률을 높여

```
model.add(Conv2D(32, kernel_size=(3, 3), input_shape=(28, 28, 1),
activation='relu'))
```

4 컨볼루션 신경망(CNN)

- 여기에 입력된 4가지 인자는 다음과 같음

  1 첫 번째 인자: 마스크를 몇 개 적용할지 정함

  여러개의 마스크를 적용하면 서로 다른 컨볼루션이 여러개 나옴

  여기서는 32개의 마스크를 적용함

  2 kernel_size: 마스크(커널)의 크기를 정함

  kernel_size=(행, 열) 형식으로 정하며, 여기서는 3×3 크기의 마스크를 사용하게끔 정함

4 컨볼루션 신경망(CNN)

3 input_shape: Dense 층과 마찬가지로 맨 처음 층에는 입력되는 값을 알려주어야함

input_shape=(행, 열, 색상 또는 흑백) 형식으로 정함

만약 입력 이미지가 색상이면 3, 흑백이면 1을 지정함

4 activation: 활성화 함수를 정의함

4 컨볼루션 신경망(CNN)

- 컨볼루션 층을 하나 더 추가함
- 다음과 같이 마스크 64개를 적용한 새로운 컨볼루션 층을 추가할 수 있음

```
model.add(Conv2D(64, (3, 3), activation='relu'))
```

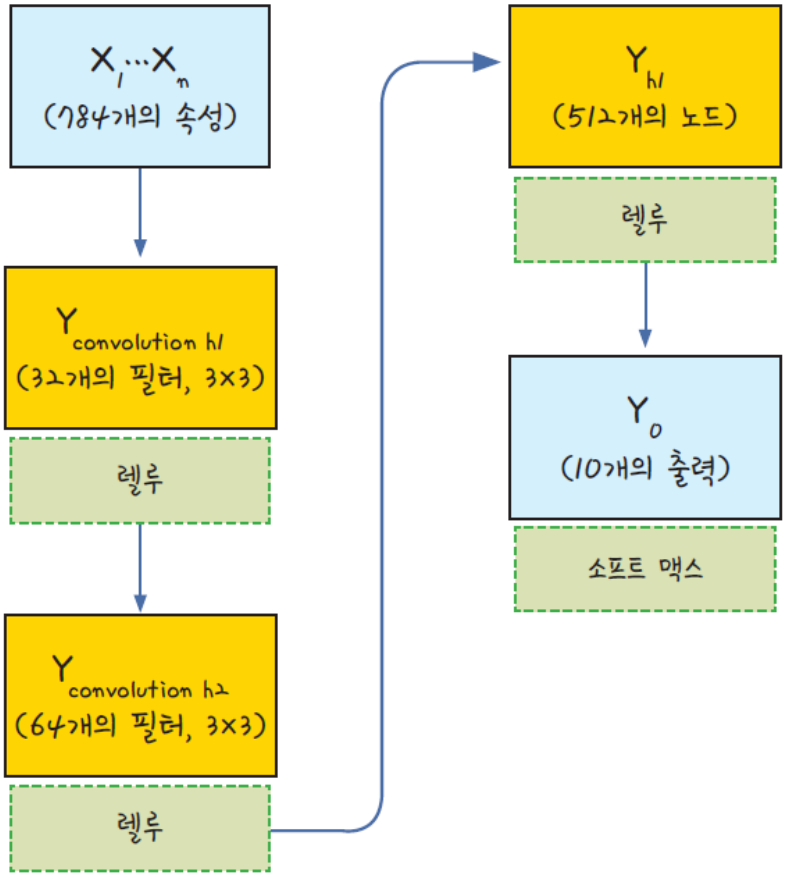

그림 16-6 컨볼루션 층의 적용

5 맥스 풀링

- 풀링(pooling) 또는 서브 샘플링(sub sampling) :

  앞서 구현한 컨볼루션 층을 통해 이미지 특징을 도출함

  그 결과가 여전히 크고 복잡하면 이를 다시 한번 축소해야 함

- 맥스 풀링(max pooling) :

  풀링 기법에는 정해진 구역 안에서 최댓값을 뽑아내는 것

- 평균 풀링(average pooling) :

  평균값을 뽑아내는 것

5 맥스 풀링

- 이중 보편적으로 사용되는 맥스 풀링의 예를 들어 보자

1	0	1	0
0	4	2	0
0	1	6	1
0	0	1	0

5 맥스 풀링

- 맥스 풀링을 적용하면 다음과 같이 구역을 나눔

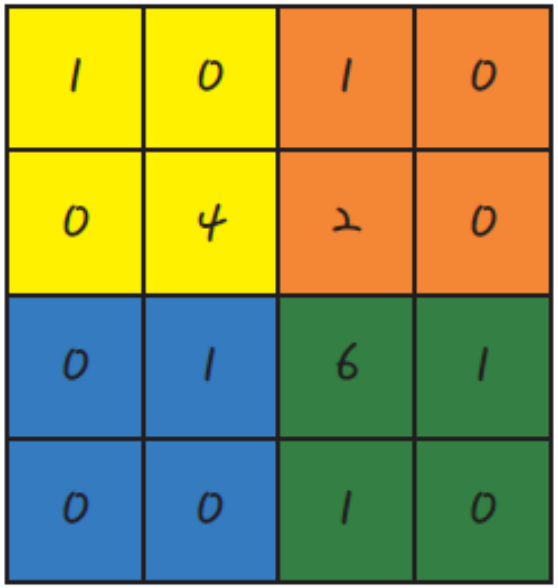

5 맥스 풀링

- 각 구역에서 가장 큰 값을 추출함

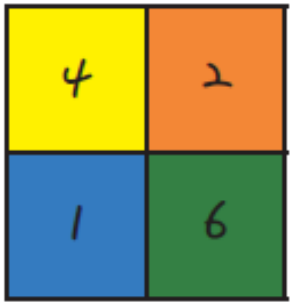

5 맥스 풀링

- 이 과정을 거쳐 불필요한 정보를 간추림

```
model.add(MaxPooling2D(pool_size=2))
```

5 맥스 풀링

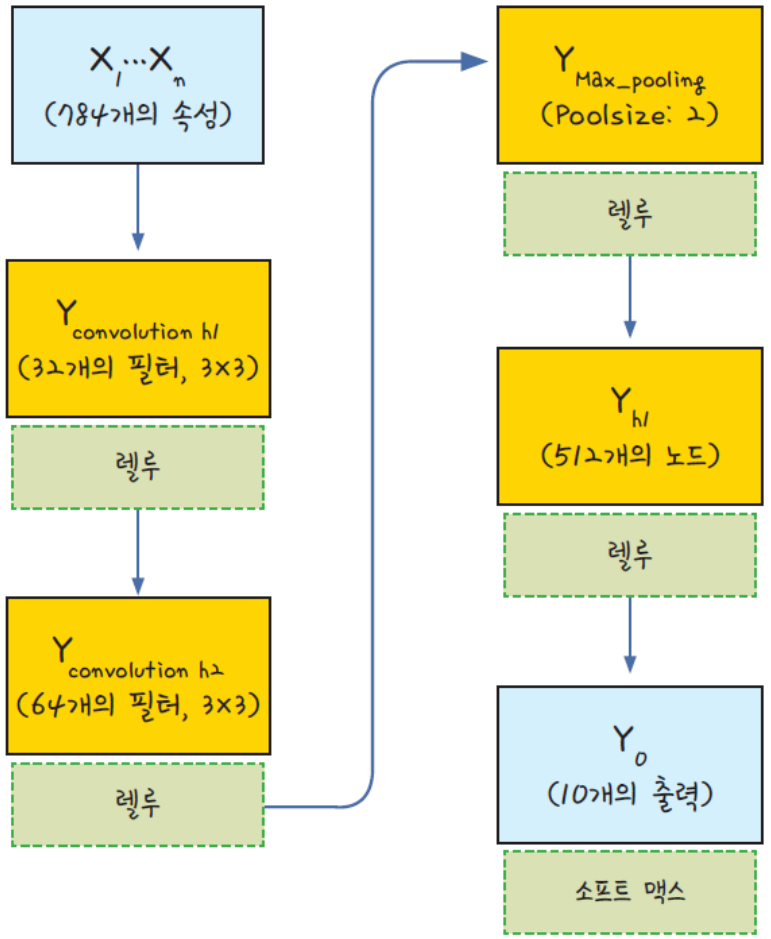

그림 16-5 은닉층이 하나인 딥러닝 모델의 도식

- 여기서 pool_size는 풀링 창의 크기를 정하는 것으로,
  - → 2로 정하면 전체 크기가 절반으로 줄어듦

5 맥스 풀링

드롭아웃, 플래튼

- 딥러닝 학습을 실행할 때 가장 중요한 것은 과적합을 얼마나 효과적으로 피해가는지에 달려 있다고 해도 과언이 아님
- 그동안 이러한 과정을 도와주는 기법이 연구되어 옴
- 그중 간단하지만 효과가 큰 기법이 바로 드롭아웃(drop out) 기법임
- 드롭아웃은 은닉층에 배치된 노드 중 일부를 임의로 꺼주는 것

5 맥스 풀링

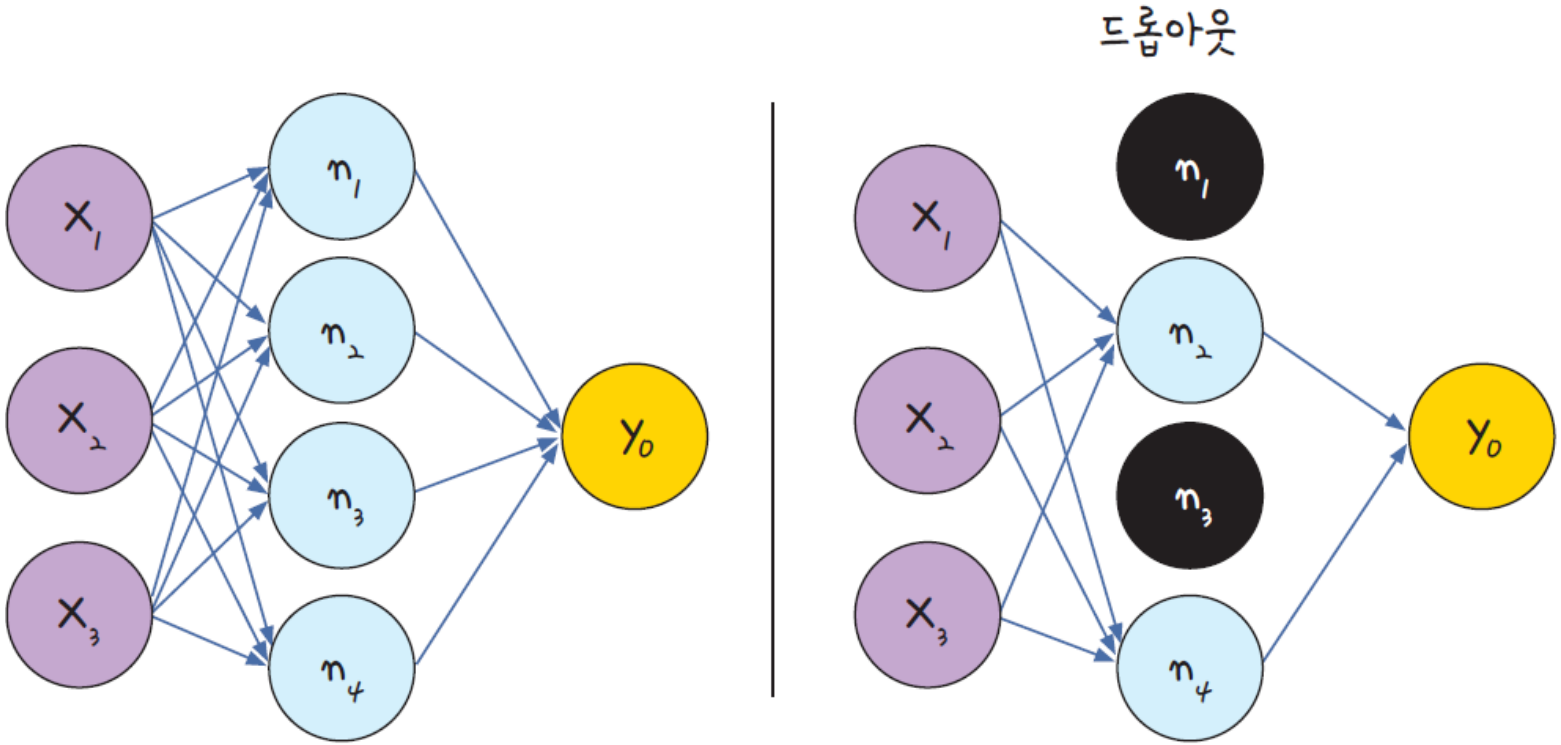

그림 16-8 드롭아웃의 개요, 검은색으로 표시된 노드는 계산하지 않는다.

5 맥스 풀링

- 랜덤하게 노드를 끔으로써 학습 데이터에 지나치게 치우쳐서 학습되는 과적합을 방지할 수 있음
- 케라스는 이를 손쉽게 적용하도록 도와줌

```
model.add(Dropout(0.25))
```

5 맥스 풀링

- 이제 이러한 과정을 지나 다시 앞에서 Dense( ) 함수를 이용해 만들었던 기본 층에 연결해 볼때
  - → 이때 주의할 점은 컨볼루션 층이나 맥스 풀링은 주어진 이미지를 2차원
    배열인 채로 다룬다는 점임
  - → 이를 1차원 배열로 바꿔주어야 활성화 함수가 있는 층에서 사용할 수

```
model.add(Flatten( ))
```

5 맥스 풀링

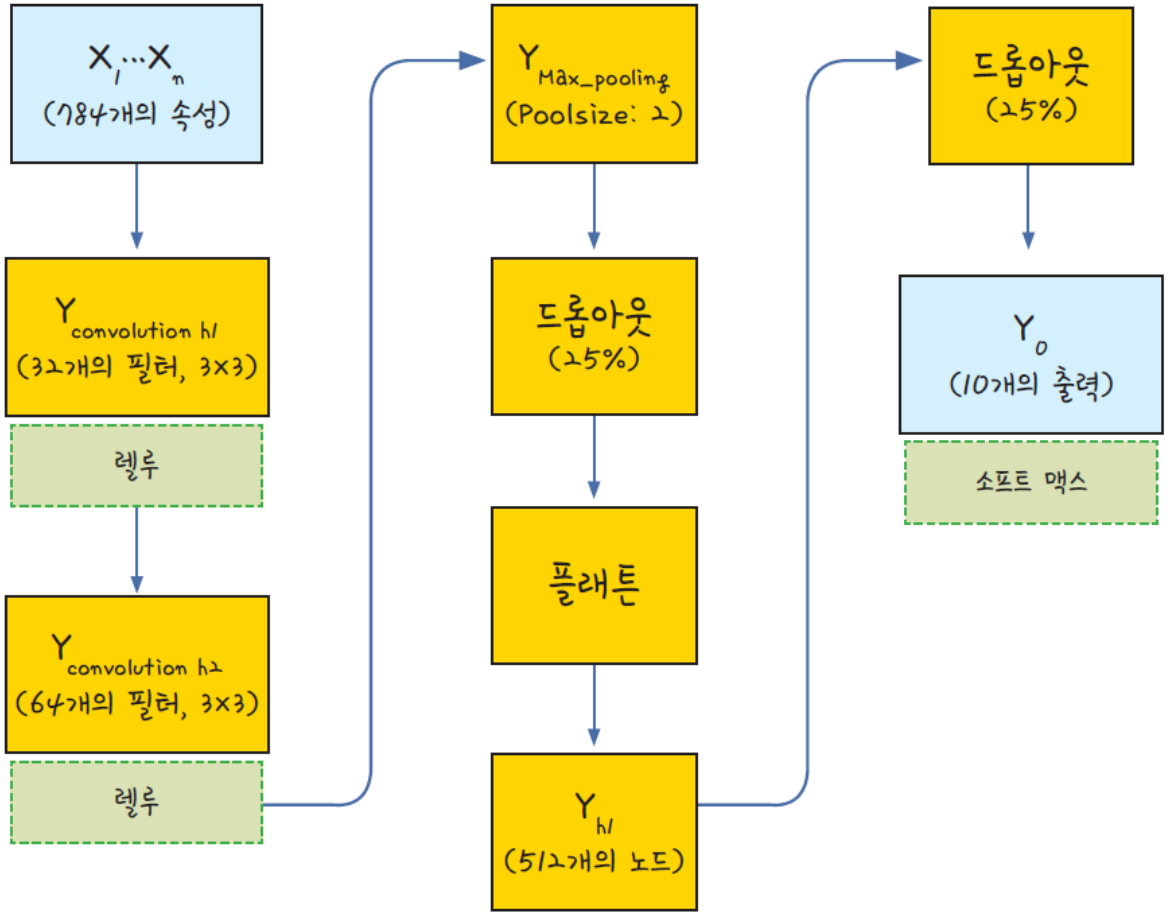

그림 16-9 드롭아웃과 플래튼 추가하기

6 컨볼루션 신경망 실행하기

- 앞서 코드 16-2에서 만든 딥러닝 기본 프레임을 그대로 이용하되 model 설정 부분만 지금까지 나온 내용으로 바꿔주면 됨

코드 16-3 MNIST 손글씨 인식하기: 컨볼루션 신경망 적용

- 예제 소스: run_project/16_MNIST_Deep.ipynb

```
from keras.datasets import mnist
from keras.utils import np_utils
from keras.models import Sequential
from keras.layers import Dense, Dropout, Flatten, Conv2D,
MaxPooling2D
from keras.callbacks import ModelCheckpoint,EarlyStopping
```

6 컨볼루션 신경망 실행하기

```
import matplotlib.pyplot as plt
import numpy
import os
import tensorflow as tf

# seed 값 설정
seed = 0
numpy.random.seed(seed)
tf.random.set_seed(3)
```

6 컨볼루션 신경망 실행하기

```
# 데이터 불러오기
(X_train, Y_train), (X_test, Y_test) = mnist.load_data( )
X_train = X_train.reshape(X_train.shape[0], 28, 28,
1).astype('float32') / 255
X_test = X_test.reshape(X_test.shape[0], 28, 28,
1).astype('float32') / 255
Y_train = np_utils.to_categorical(Y_train)
Y_test = np_utils.to_categorical(Y_test)
```

6 컨볼루션 신경망 실행하기

```
# 컨볼루션 신경망 설정
model = Sequential( )
model.add(Conv2D(32, kernel_size=(3, 3), input_shape=(28, 28, 1),
activation='relu'))
model.add(Conv2D(64, (3, 3), activation='relu'))
model.add(MaxPooling2D(pool_size=2))
model.add(Dropout(0.25))
model.add(Flatten( ))
model.add(Dense(128, activation='relu'))
model.add(Dropout(0.5))
```

6 컨볼루션 신경망 실행하기

```
model.add(Dense(10, activation='softmax'))

model.compile(loss='categorical_crossentropy',
              optimizer='adam',
              metrics=['accuracy'])

# 모델 최적화 설정
MODEL_DIR = './model/'
if not os.path.exists(MODEL_DIR):
    os.mkdir(MODEL_DIR)
```

6 컨볼루션 신경망 실행하기

```
modelpath="./model/{epoch:02d}-{val_loss:.4f}.hdf5"
checkpointer = ModelCheckpoint(filepath=modelpath, monitor='val_
loss', verbose=1, save_best_only=True)
early_stopping_callback = EarlyStopping(monitor='val_loss',
patience=10)

# 모델의 실행
history = model.fit(X_train, Y_train, validation_data=(X_test, Y_
test), epochs=30, batch_size=200, verbose=0, callbacks=[early_
stopping_callback,checkpointer])
```

6 컨볼루션 신경망 실행하기

```
# 테스트 정확도 출력
print("\n Test Accuracy: %.4f" % (model.evaluate(X_test, Y_test)
[1]))

# 테스트셋의 오차
y_vloss = history.history['val_loss']

# 학습셋의 오차
y_loss = history.history['loss']
```

6 컨볼루션 신경망 실행하기

```
# 그래프로 표현
x_len = numpy.arange(len(y_loss))
plt.plot(x_len, y_vloss, marker='.', c="red", label='Testset_
loss')
plt.plot(x_len, y_loss, marker='.', c="blue", label='Trainset_
loss')

# 그래프에 그리드를 주고 레이블을 표시
plt.legend(loc='upper right')
plt.grid()
plt.xlabel('epoch')
plt.ylabel('loss')
plt.show()
```

6 컨볼루션 신경망 실행하기

실행 결과

```
Epoch 00000: val_loss improved from inf to 0.06068, saving model to ./model/00-0.0607.hdf5
Epoch 00001: val_loss improved from 0.06068 to 0.04409, saving model to ./model/01-0.0441.hdf5
Epoch 00002: val_loss improved from 0.04409 to 0.03909, saving model to ./model/02-0.0391.hdf5
Epoch 00003: val_loss improved from 0.03909 to 0.03188, saving model to ./model/03-0.0319.hdf5
Epoch 00004: val_loss improved from 0.03188 to 0.02873, saving model to ./model/04-0.0287.hdf5
Epoch 00005: val_loss did not improve
Epoch 00006: val_loss did not improve
Epoch 00007: val_loss did not improve
Epoch 00008: val_loss improved from 0.02873 to 0.02678, saving model to ./model/08-0.0268.hdf5
```

6 컨볼루션 신경망 실행하기

```
Epoch 00009: val_loss did not improve
Epoch 00010: val_loss improved from 0.02678 to 0.02617, saving model to ./model/10-0.0262.hdf5
Epoch 00011: val_loss did not improve
Epoch 00012: val_loss did not improve
Epoch 00013: val_loss improved from 0.02617 to 0.02454, saving model to ./model/13-0.0245.hdf5
Epoch 00014: val_loss did not improve
Epoch 00015: val_loss did not improve
Epoch 00016: val_loss did not improve
Epoch 00017: val_loss did not improve
```

6 컨볼루션 신경망 실행하기

```
Epoch 00018: val_loss did not improve
Epoch 00019: val_loss did not improve
Epoch 00020: val_loss did not improve
Epoch 00021: val_loss did not improve
Epoch 00022: val_loss did not improve
Epoch 00023: val_loss did not improve
Epoch 00024: val_loss did not improve

Test Accuracy: 0.9928
```

TIP

CPU 기반으로 코드 16-3을 실행하면 앞서 다룬 예제보다 시간이 더 오래 걸릴 것입니다. 이 책에서 소개한 작은 프로젝트 정도면 CPU에서 실습해도 큰 상관이 없지만, 더 큰 딥러닝 프로젝트는 반드시 GPU 환경을 갖추어 시행할 것을 추천합니다. 또한, 결과는 실행할 때마다 다를 수도 있습니다.

6 컨볼루션 신경망 실행하기

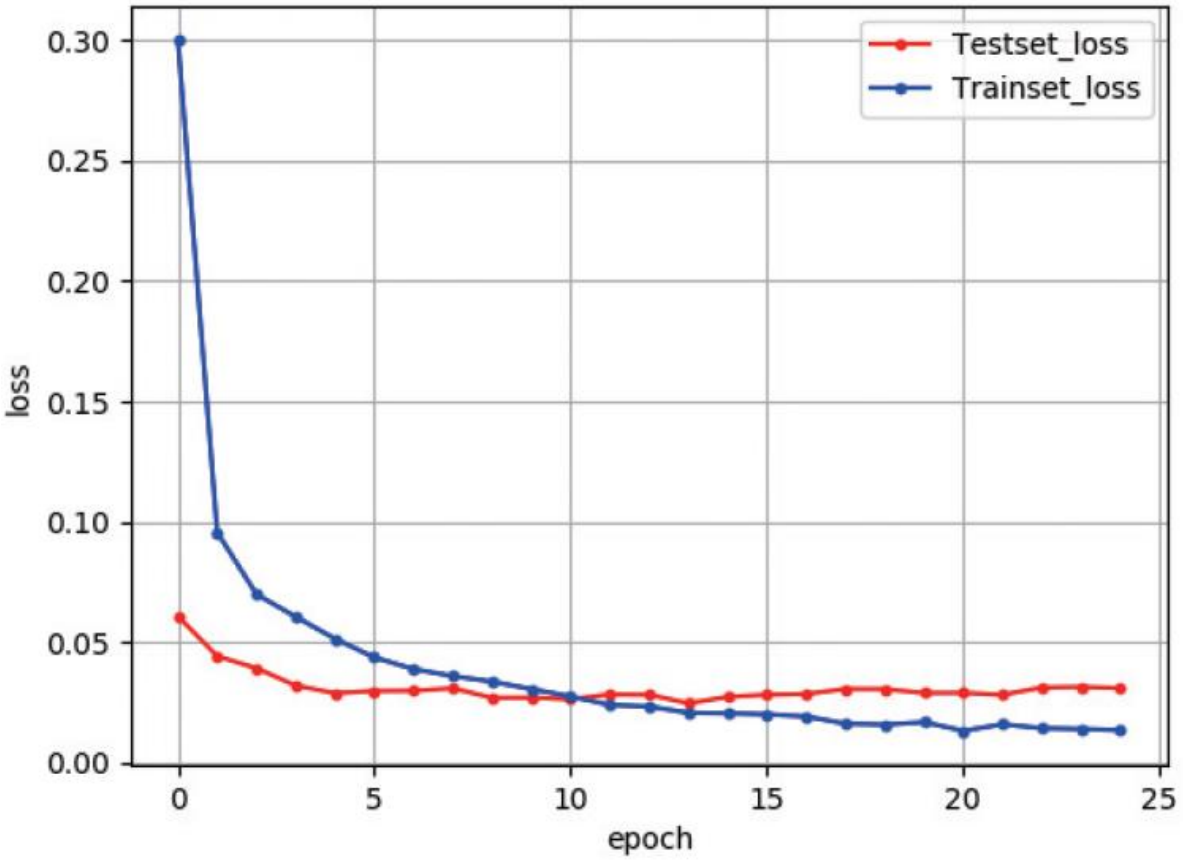

그림 16-10 학습의 진행에 따른 학습셋과 테스트셋의 오차 변화

6 컨볼루션 신경망 실행하기

- 100% 다 맞히지 못한 이유는 데이터 안에 다음과 같이 확인할 수 없는 글씨가 있었기 때문임

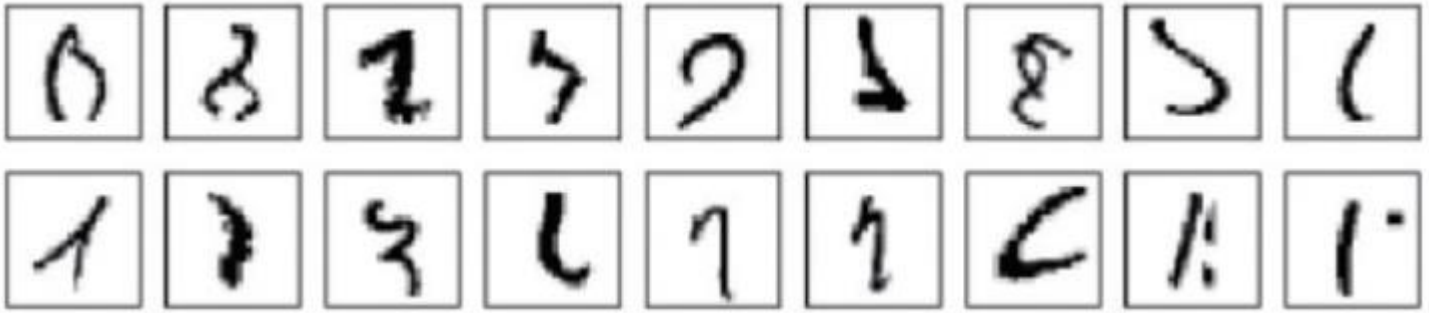

그림 16-11 알아내지 못한 숫자의 예